

Capitulo 3

Santiago Espinoza

René Delgado

3.1

Para la Tabla 3.4 La hipótesis nulea para cada predictor, ya sea TV, radio o periodico, dice que la cantidad de dinero invertida en estas no tiene efecto sobre el número de ventas. Los p-valores pequeños indican que la hipotesis nula se puede descartar en el caso de TV y radio. Como el p-valor de periodico es grande, se puede tomar su hipotesis nula como cierta.

3.2

La diferencia en entre la regresión por K vecinos cercanos con el clasificador de K vecinos cercanos, radica en el enfoque, durante la regresión estamos estimando y usando el promedio de los valores de y de los K vecinos más cercanos, en el clasificador se calcula la probabilidad condicional como 1/K por la cantidad de vecinos de una clase en particular, no se realiza nigún promedio.

3.3

```
Y = 50 + 20(GPA) + 0.07(IQ) + 35(Gender) + 0.01(GPA \& IQ) - 10(GPA \& Gender) tenemos: 
 male - gender = 0 
 Y = 50 + 20(GPA) + 0.07(IQ) + 0.01(GPA \& IQ) female - gender = 0 
 Y = 50 + 20(GPA) + 0.07(IQ) + 35(Gender) + 0.01(GPA \& IQ) - 10(GPA \& Gender)
```

a)

Si se tienen valores fijos de IQ y GPA, los hombres ganan mas que las mujeres dado un GPA lo suficientemente alto.

b)

c)

Falso, se debe tomar en cuenta el tamaño del p-valor del predicot par ver si este tiene algun efecto, o no, sobre la salida

3.4

a)

Dentro de la reresión cúbica se encuentra la regresión lineal. El RSS debe de mantenerse similar por lo mismo, tal vez siendo ligeramente menor el de la cúbica, los p-valores de los coeficientes cúbicos y cuadrático deben de resultar altos.

b)

El RSS del set de prueba para la estimación cúbica va a ser más alto que el de la estimación lineal, pues se puede aproximar una cúbica a una lineal en una localidad; sin embargo en los extremos se aleja del comportamiento lineal más y más. Además como teníamos más libertad en la curva existe la posibilidad de que se ajustara ligeramente al error en los datos de entremiento empeorando aun más el RSS del set de prueba.

c)

En este caso el RSS de la regresión cúbica es mejor(menor) que el de la lineal.

d)

Considerando que el set de entrenamiento y de verificación están bien seleccionados, la predicción cúbica debe tener mejor RSS.

3.5

$$\hat{y}_i^{'}=x_{i}^{}\hat{B}$$

$$\hat{\boldsymbol{B}} = \frac{\sum \boldsymbol{x}_i \boldsymbol{y}_i}{\sum \boldsymbol{x}_k 2}$$

Sustituimos $\hat{\boldsymbol{B}}$ en $\hat{\boldsymbol{y}}^i$

$$\hat{y}^i = x_i \underbrace{\sum x_i^{} y_i^{}}_{\sum x_2^{}} = \underbrace{\sum (\underbrace{x_i^{} x_i^{}}_{\sum x_2^{}}) y_i^{}}_{k}$$

tomamos:

$$a_i^{'} = rac{x_i^{'}x_i^{}}{\sum\limits_k^{}x_2^{}}$$

y obtenemos:

$$\hat{y}^i = \sum a^{\cdot}_i y^{\cdot}_i$$

3.6

Tomando en cuenta:

$$\hat{eta}^0 = ar{y} - \hat{eta}^{1ar{z}}$$

Es obvio que siempre para el promedio en x le corespondera el promedio en y.

3.7

Probar que:

$$\boldsymbol{R}_{\boldsymbol{2}} = \operatorname{corr}_{\boldsymbol{2}}(\boldsymbol{x}, \boldsymbol{y})$$

Tenemos que

$$R_{2} = \frac{TSS - RSS}{TSS}$$

donde

$$TSS = \sum (y_i^{} - \overline{y})_2^{}$$

$$RSS = \sum (y_i - {}_{\hat{y}^i})_2$$

$$corr(x,y) = \underbrace{\frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sigma_x \sigma_y}}$$

$$\sigma_{\stackrel{2}{x}}=\sum(x_i^{}-_{\bar{x}}^{})$$

$$\sigma_{\stackrel{2}{y}} = \sum (y_i - \overline{y})$$

$$R_2 = \underbrace{\frac{\sum (y_i - \bar{y})_2 - \sum (y_i - \hat{y}^i)_2}{\sum (y_i - \bar{y})_2}} = \underbrace{\frac{\sum (\hat{y}^i - \bar{y})(2y_i - \bar{y} - \hat{y}^i)}{\sum (y_i - \bar{y})_2}}$$

Recordamos que:

ParseError: KaTeX parse error: No such environment: align at position 7: \begin{align} \hat{\beta}_...

Subsittuimos \hat{eta}^0 en \hat{y}^i

ParseError: KaTeX parse error: No such environment: align at position 7: \begin{align} \hat{y}_i &=...

Se toman las expresiones $\hat{y}^i-\bar{y}$ y $2y_i-\bar{y}-\hat{y}^i$ del numerador de R_2 y se hace un subsitucion de acuerdo a las expresiones anteriores

ParseError: KaTeX parse error: No such environment: align at position 7: \begin{align} \hat{...} Se substituyen estas expresiones en el numerador de R_2

\$\$

```
&= \sum \hat{\beta}_1 (x_i - \hat{x})
\left[ 2(y_i - \bar{y}) - \hat{\beta}_1 (x_i - \bar{x}) \right] \
&= \hat{\beta}_1 \sum (x_i - \bar{x})
\left[ 2(y_i - \bar{y}) -
\hat{\beta}_1 (x_i - \bar{x}) \right] \
&= \hat{\beta}_1
\left[ 2 \sum (x_i - \bar{x}) \(y_i - \bar{y}) -
\hat{\beta}_1 \sum (x_i - \bar{x})(y_i - \bar{y}) -
\hat{\beta}_1 \sum (x_i - \bar{x})^2 \label{A4} \right]
\left[ 2 \sum (align)
$$
```

Usando la ecuacion para $\hat{\boldsymbol{\beta}}^1$ se simplifica la expresion anterior y se obtiene

ParseError: KaTeX parse error: No such environment: align at position 7: \begin{align} A &= \hat{\b...}

Se reemplaza esto en el numerador de $R_{\scriptscriptstyle 2}$ y se obtiene finalmente

$$R_2 = \frac{\left[\sum (x_i - \frac{1}{x})(y_i - \frac{1}{y})\right]_2}{\sum (x_j - \frac{1}{x})_2^2 \sum (y_k - \frac{1}{y})_2} = R_2 = corr_2(x, y)$$

3.8

a)

Input:

```
library(ISLR)
Auto <- na.omit(Auto)

reg_01 <- lm(mpg ~ horsepower, data = Auto)
summary(reg_01)</pre>
```

Output:

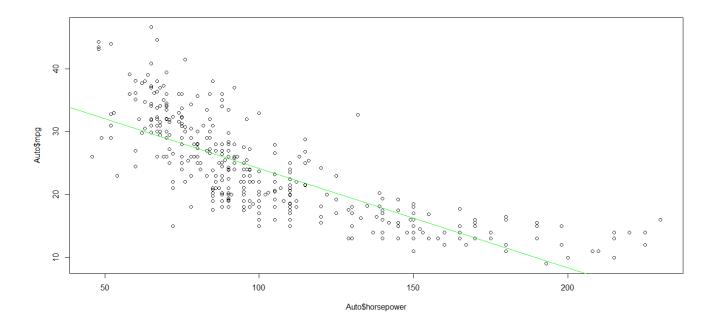
Primero fijándonos en los p valores se observa que si existe una relación, no muy fuerte pues el valor del coeficiente es ~-0.15, el valor absoluto de este con relación a la desviación estandar de ~7.8 es muy pequeño; además se observa una relación negativa.

Realizando predicciones para el valor de 98 en horsepower:

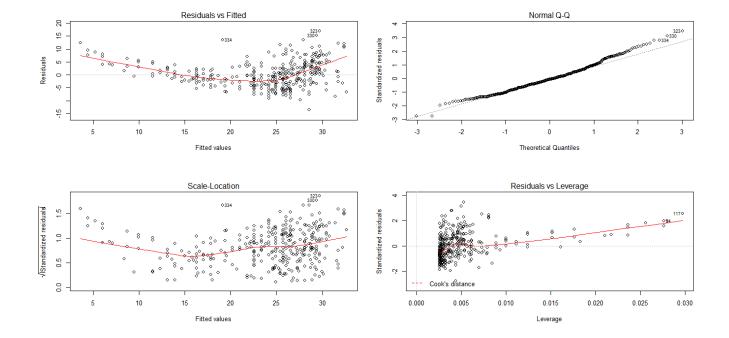
```
pred1 <- predict(reg_01, data.frame(horsepower = c(98)),interval='confidence')
print(pred1)
pred2 <- predict(reg_01, data.frame(horsepower = c(98)),interval='prediction')
print(pred2)</pre>
```

El valor de la predicción es 24.46708, con intervalos de confianza de 23.97308 a 24.96108 e intervalos de predicción de 14.8094 a 34.12476.

b)



c)

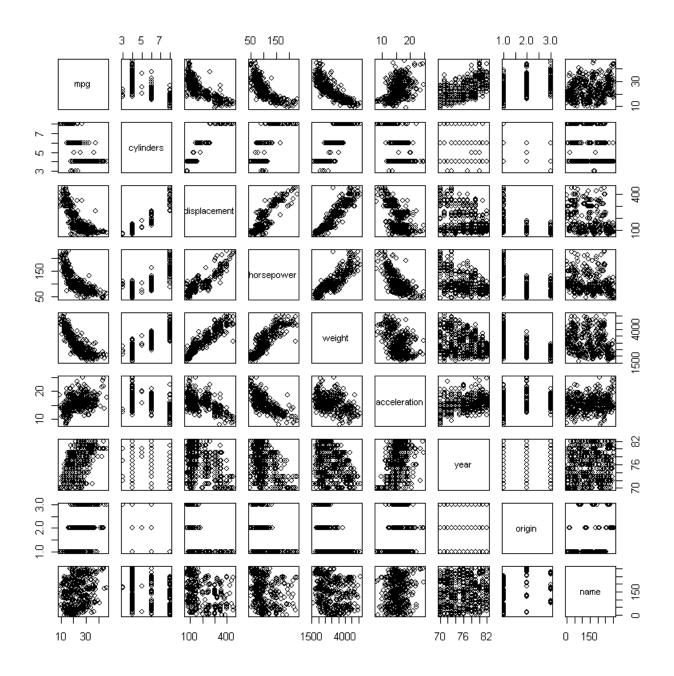


Se obseva que más o menos si sigue una distribución normal sin embargo exceptuaando normal Q-Q el resto de las graficas no siguen el comportamiento dedibo. Esto es debido que la relación real no es lineal, es cuadrática.

3.9

a)

```
library(ISLR)
attach(Auto)
pairs(Auto)
```



b)

cor(subset(Auto, select=-name))

A matrix: 8 × 8 of type dbl

	mpg	cylinders	displacement	horsepower	weight	acc
mpg	1.0000000	-0.7776175	-0.8051269	-0.7784268	-0.8322442	0.42

	mpg	cylinders	displacement	horsepower	weight	acce
cylinders	-0.7776175	1.0000000	0.9508233	0.8429834	0.8975273	-0.50
displacement	-0.8051269	0.9508233	1.0000000	0.8972570	0.9329944	-0.54
horsepower	-0.7784268	0.8429834	0.8972570	1.0000000	0.8645377	-0.68
weight	-0.8322442	0.8975273	0.9329944	0.8645377	1.0000000	-0.4
acceleration	0.4233285	-0.5046834	-0.5438005	-0.6891955	-0.4168392	1.00
year	0.5805410	-0.3456474	-0.3698552	-0.4163615	-0.3091199	0.29
origin	0.5652088	-0.5689316	-0.6145351	-0.4551715	-0.5850054	0.21

c)

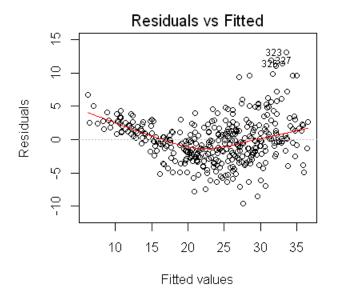
```
lm.fit1 = lm(mpg~.-name, data=Auto)
summary(lm.fit1)
```

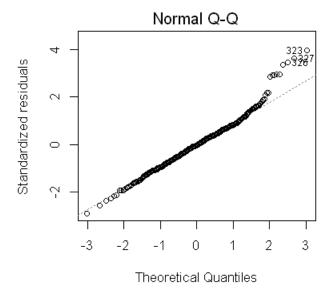
```
Call:
lm(formula = mpg ~ . - name, data = Auto)
Residuals:
   Min
        1Q Median 3Q
-9.5903 -2.1565 -0.1169 1.8690 13.0604
Coefficients:
           Estimate Std. Error t value Pr(>|t|)
(Intercept) -17.218435  4.644294 -3.707  0.00024 ***
        cylinders
displacement 0.019896 0.007515 2.647 0.00844 **
          -0.016951 0.013787 -1.230 0.21963
horsepower
          weight
acceleration 0.080576 0.098845 0.815 0.41548
          year
origin
          1.426141 0.278136 5.127 4.67e-07 ***
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 3.328 on 384 degrees of freedom
Multiple R-squared: 0.8215, Adjusted R-squared: 0.8182
F-statistic: 252.4 on 7 and 384 DF, p-value: < 2.2e-16
```

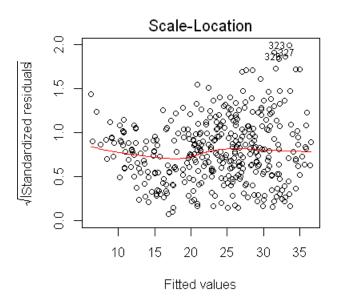
- i. Si existe relacion entre los predictores y la respuesta. Si se observan los p-valores de algunos predictores, como weight, year, origin, se puede obervar que son muy pequeños y por tanto se puede negar la hipotesis nula. Tambien se tiene un valor de la estadística-F lejano de 1.
- ii. Los predictores maás significativos son weight, year y origin.
- iii. El coeficiente del predictor year nos dice que conforme pasan los años incrementa la eficiencia de los automoviles.

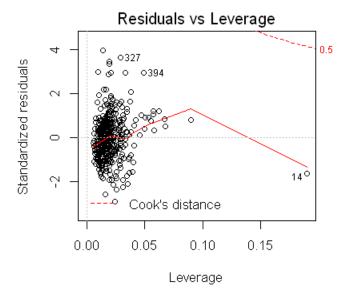
d)

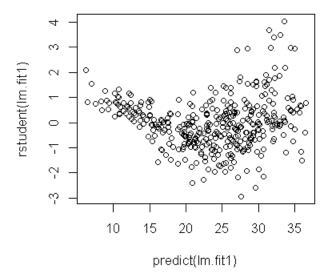
```
par(mfrow=c(2,2))
plot(lm.fit1)
plot(predict(lm.fit1), rstudent(lm.fit1))
```











Se observa una curvatura en el fit. En el plit de leverage, el punto 14 tiene un nivel alto de leverage. En el plot de student se observan datos arriba de 3, los cuales pueden ser valores atípicos.

e)

```
lm.fit2 = lm(mpg~cylinders*displacement+displacement*weight)
summary(lm.fit2)
```

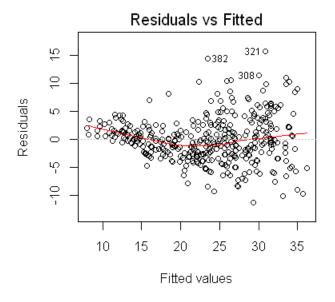
```
Call:
lm(formula = mpg ~ cylinders * displacement + displacement *
   weight)
Residuals:
    Min
          1Q Median 3Q
-13.2934 -2.5184 -0.3476 1.8399 17.7723
Coefficients:
                     Estimate Std. Error t value Pr(>|t|)
                   5.262e+01 2.237e+00 23.519 < 2e-16 ***
(Intercept)
cylinders
                    7.606e-01 7.669e-01 0.992 0.322
displacement
                   -7.351e-02 1.669e-02 -4.403 1.38e-05 ***
                    -9.888e-03 1.329e-03 -7.438 6.69e-13 ***
weight
cylinders:displacement -2.986e-03 3.426e-03 -0.872 0.384
displacement:weight 2.128e-05 5.002e-06 4.254 2.64e-05 ***
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 4.103 on 386 degrees of freedom
Multiple R-squared: 0.7272, Adjusted R-squared: 0.7237
F-statistic: 205.8 on 5 and 386 DF, p-value: < 2.2e-16
```

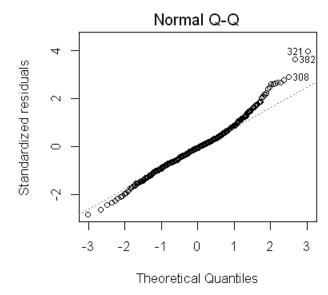
Se tomaron los pares con mayor correlacion, de acuerdo a la matriz de correlaciones. Se puede observar que los valores-p de la interacción entre desplazamiento y peso son pequeños, lo cual indica que sí es significativa. Para cylinders y displacement, el p-valor es grande, por tanto su interacción no es significativa.

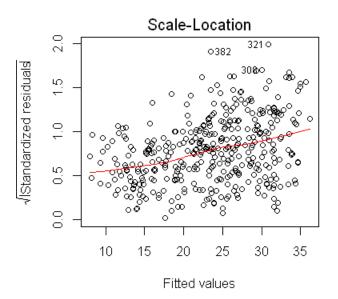
f)

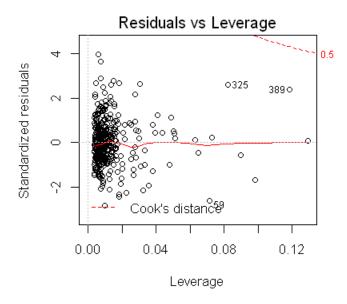
```
#sqrt
lm.fit3 = lm(mpg~log(weight)+sqrt(horsepower)+acceleration+I(acceleration^2))
summary(lm.fit3)
par(mfrow=c(2,2))
plot(lm.fit3)
plot(predict(lm.fit3), rstudent(lm.fit3))
```

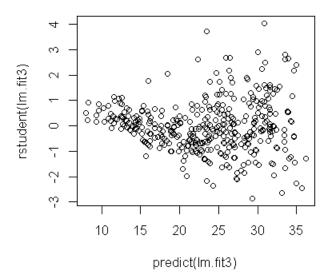
```
Call:
lm(formula = mpg ~ log(weight) + sqrt(horsepower) + acceleration +
   I(acceleration^2))
Residuals:
    Min 1Q Median 3Q
                                 Max
-11.2932 -2.5082 -0.2237 2.0237 15.7650
Coefficients:
               Estimate Std. Error t value Pr(>|t|)
              (Intercept)
log(weight) -14.74259 1.73994 -8.473 5.06e-16 ***
sqrt(horsepower) -1.85192 0.36005 -5.144 4.29e-07 ***
acceleration
            -2.19890 0.63903 -3.441 0.000643 ***
I(acceleration^2) 0.06139 0.01857 3.305 0.001037 **
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 3.99 on 387 degrees of freedom
Multiple R-squared: 0.7414, Adjusted R-squared: 0.7387
F-statistic: 277.3 on 4 and 387 DF, p-value: < 2.2e-16
```





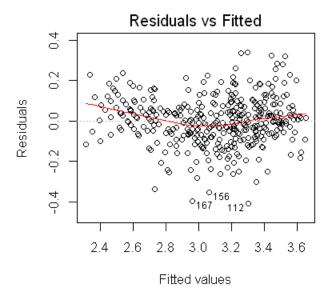


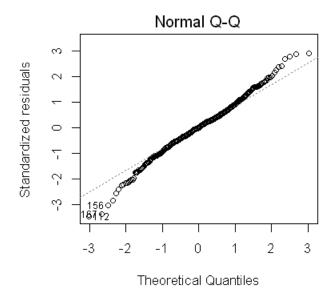


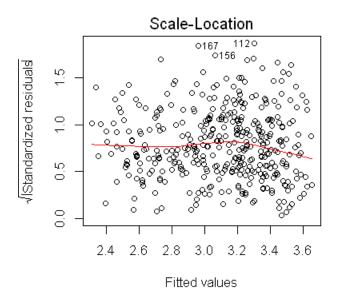


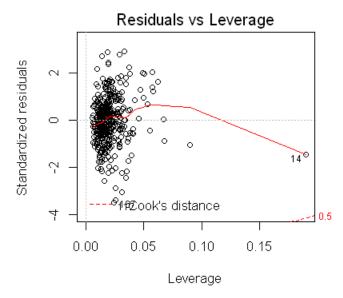
```
#log
lm.fit4<-lm(log(mpg)~cylinders+displacement+horsepower+weight+acceleration+year+origin,data=Auto)
summary(lm.fit4)
par(mfrow=c(2,2))
plot(lm.fit4)
plot(predict(lm.fit4),rstudent(lm.fit4))</pre>
```

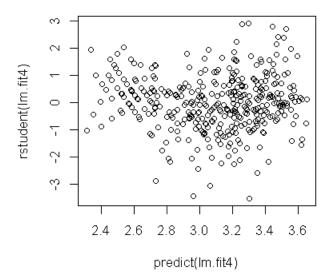
```
Call:
lm(formula = log(mpg) ~ cylinders + displacement + horsepower +
   weight + acceleration + year + origin, data = Auto)
Residuals:
    Min
           1Q Median 3Q
-0.40955 -0.06533 0.00079 0.06785 0.33925
Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) 1.751e+00 1.662e-01 10.533 < 2e-16 ***
cylinders -2.795e-02 1.157e-02 -2.415 0.01619 *
displacement 6.362e-04 2.690e-04 2.365 0.01852 *
horsepower -1.475e-03 4.935e-04 -2.989 0.00298 **
           -2.551e-04 2.334e-05 -10.931 < 2e-16 ***
weight
acceleration -1.348e-03 3.538e-03 -0.381 0.70339
           2.958e-02 1.824e-03 16.211 < 2e-16 ***
year
           4.071e-02 9.955e-03 4.089 5.28e-05 ***
origin
Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.1191 on 384 degrees of freedom
Multiple R-squared: 0.8795, Adjusted R-squared: 0.8773
F-statistic: 400.4 on 7 and 384 DF, p-value: < 2.2e-16
```











3.10

a)

Input:

```
library(ISLR)
Carseats <- na.omit(Carseats)

reg1 <- lm(Sales ~ US + Urban +Price, data=Carseats)
summary(reg1)</pre>
```

Output:

```
Call:
lm(formula = Sales ~ US + Urban + Price, data = Carseats)
Residuals:
   Min 1Q Median 3Q
                              Max
-6.9206 -1.6220 -0.0564 1.5786 7.0581
Coefficients:
          Estimate Std. Error t value Pr(>|t|)
1.200573 0.259042 4.635 4.86e-06 ***
USYes
UrbanYes -0.021916 0.271650 -0.081 0.936
       -0.054459 0.005242 -10.389 < 2e-16 ***
Price
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 2.472 on 396 degrees of freedom
Multiple R-squared: 0.2393, Adjusted R-squared: 0.2335
F-statistic: 41.52 on 3 and 396 DF, p-value: < 2.2e-16
```

b) y d)

Se observa primero que UrbanYes tiene un valor p muy alto, por lo que no es relevante para el modelo. Además se observa que conforme el precio crece las ventas disminuyen y si la tienda es de estados unidos las ventas aumentan.

c)

```
\hat{y} = egin{cases} US = Urban = Yes & Intercept + USYes + UrbanYes + Prices(x) \ US = Yes \& Urban = No & Intercept + USYes + Prices(x) \ US = No \& Urban = Yes & Intercept + UrbanYes + Prices(x) \ US = No \& Urban = No & Intercept + Prices(x) \end{cases}
```

Donde x es el precio.

e) y f)

Input:

```
reg2 <- lm(Sales ~ US + Price,data=Carseats)
summary(reg2)
par(mfrow = c(2, 2))
plot(reg2)</pre>
```

Output:

```
Call:
lm(formula = Sales ~ US + Price, data = Carseats)
Residuals:
      1Q Median 3Q
   Min
                            Max
-6.9269 -1.6286 -0.0574 1.5766 7.0515
Coefficients:
         Estimate Std. Error t value Pr(>|t|)
USYes 1.19964 0.25846 4.641 4.71e-06 ***
        Price
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 2.469 on 397 degrees of freedom
Multiple R-squared: 0.2393, Adjusted R-squared: 0.2354
F-statistic: 62.43 on 2 and 397 DF, p-value: < 2.2e-16
```

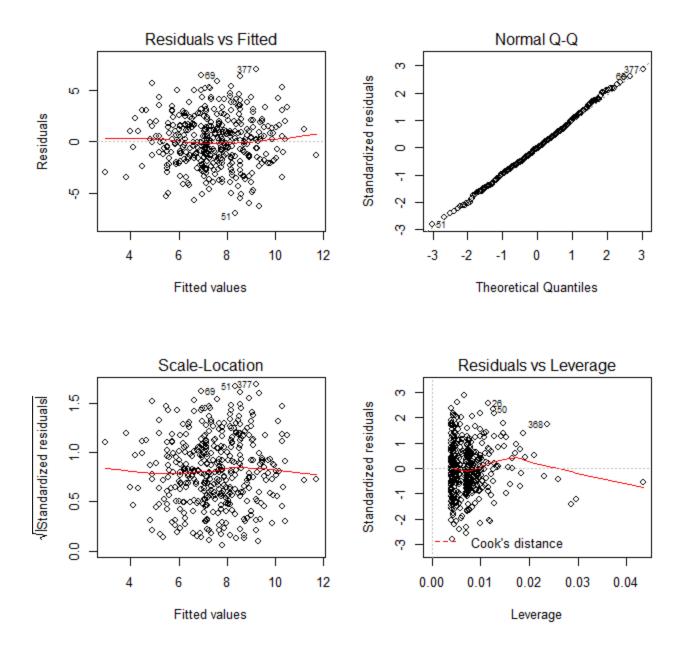
Se observa que este modelo tienen un error practicamente igual al del modelo pasado.

g)

Los intevalos obtenidos usado la función:

```
confint(reg2)
```

Fueron de 11.79 a 14.271 para el *intercepto*, 0.691 a 1.708 para USYes y -0.065 a -0.442 para *Price*, redondeando a tres digitos.



Existe un valor observable de la gráfica Residuals vs Leverage que tienen mucha influencia y está muy separado del resto de los valores, tal vez convenga eliminnar ese valor.

3.11

```
set.seed(1)
x = rnorm(100)
y = 2*x + rnorm(100)

lm.fit = lm(y~x+0)
summary(lm.fit)
```

El p-valor es pequeño y la estadistica F es lejana de 1, por tanto se puede negar la hipótesis núla.

b)

```
lm.fit1 = lm(x~y+0)
summary(lm.fit1)
```

```
Call:
lm(formula = x \sim y + 0)
Residuals:
   Min 1Q Median 3Q
                                 Max
-0.8699 -0.2368 0.1030 0.2858 0.8938
Coefficients:
  Estimate Std. Error t value Pr(>|t|)
y 0.39111 0.02089 18.73 <2e-16 ***
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.4246 on 99 degrees of freedom
Multiple R-squared: 0.7798, Adjusted R-squared: 0.7776
F-statistic: 350.7 on 1 and 99 DF, p-value: < 2.2e-16
```

Para el caso en que no se toma en cuenta el intercepto igual se puede descartar la hipótesis núla.

c)

 $y=2x+\epsilon$ se puede reescribir como $x=0.5(y-\epsilon)$ Son la misma linea.

d)

tenemos

$$\begin{array}{l} \beta = \sum\limits_{\substack{\sum x_i y_i \\ \sum x_2}} SE(\beta) = \sqrt{\sum_{\substack{(y_i - x_i \beta)_2 \\ i}}} \\ \text{Reemplazando los valores de } \beta \text{ } \sqrt{\mathcal{BE}(\beta)} \text{ } \text{ } \text{en } t \text{ obtenemos} \end{array}$$

$$t = \frac{\sum x_i y_i}{\sum x_2^i} \sqrt{\frac{\left(y_i - x_i \beta\right)_2}{(n-1)\sum x_2^i}}$$

Simplificando

$$\frac{\sqrt{n-1}\sum x_i y_i}{\sqrt{\sum x_2 \sum (y_i - x_i \beta)_2}}$$

$$\frac{\sqrt{n-1}\sum x_i y_i}{\sqrt{\sum x_2 \sum \left(y_2 - 2\beta x_i y_i + x_2 \beta_2\right)}}$$

$$\frac{\sqrt{n-1}\sum x_i y_i}{\sqrt{\sum x_2 \sum y_2 - \sum x_2 \beta(2\sum x_i y_i - \beta\sum x_2)}}$$

$$\frac{\sqrt{n-1}^{\sum x_i^{} y_i^{}}}{\sqrt{\sum x_2^{} \sum_{i}^{} y_i^{} - \sum x_i^{} y_i^{} (2 \sum x_i^{} y_i^{} - \sum x_i^{} y_i^{})}}$$

y se obtiene

$$t = \frac{\sqrt{n-1} \frac{\sum x_i y_i}{\sqrt{\sum x_2 \sum y_2 - (\sum x_i y_i)_2}}}{\sqrt{\sum x_2 \sum y_2 - (\sum x_i y_i)_2}}$$
 anterior se obtione i

comprobando con el ejemplo anterior se obtiene i

$$(\operatorname{sqrt}(\operatorname{length}(x)-1) * \operatorname{sum}(x*y)) / (\operatorname{sqrt}(\operatorname{sum}(x*x) * \operatorname{sum}(y*y) - (\operatorname{sum}(x*y))^2))$$

18.7259319374486

El cual es el mismo t-valor de la regresion sin intercepto

e)

Hacer el intercambio de t(x,y) y t(y,x) da el mismo resultado.

$$t(x,y) = t(y,x)$$

```
lm.fit2 = lm(x\sim y)
summary(lm.fit2)
   Call:
   lm(formula = x \sim y)
   Residuals:
              1Q Median 3Q
   -0.90848 -0.28101 0.06274 0.24570 0.85736
   Coefficients:
              Estimate Std. Error t value Pr(>|t|)
   (Intercept) 0.03880 0.04266 0.91 0.365
   У
              0.38942 0.02099 18.56 <2e-16 ***
   Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
   Residual standard error: 0.4249 on 98 degrees of freedom
   Multiple R-squared: 0.7784, Adjusted R-squared: 0.7762
   F-statistic: 344.3 on 1 and 98 DF, p-value: < 2.2e-16
lm.fit3 = lm(y\sim x)
summary(lm.fit3)
   Call:
   lm(formula = y \sim x)
   Residuals:
       Min 1Q Median 3Q
   -1.8768 -0.6138 -0.1395 0.5394 2.3462
   Coefficients:
              Estimate Std. Error t value Pr(>|t|)
   (Intercept) -0.03769 0.09699 -0.389 0.698
          1.99894 0.10773 18.556 <2e-16 ***
   Х
   Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
   Residual standard error: 0.9628 on 98 degrees of freedom
   Multiple R-squared: 0.7784, Adjusted R-squared: 0.7762
```

F-statistic: 344.3 on 1 and 98 DF, p-value: < 2.2e-16

los t-valores son iguales para ambos casos

3.12

a)

En el caso que:

$$x_{\stackrel{.}{i}}=y_{\stackrel{.}{i}}$$

Para toda i.

b) y c)

Input:

```
D = data.frame(y = 1:100,x = -(1:100))
D_2 = data.frame(y1 = 1:100,x1 = seq.int(1,200,2))
reg1_1 <- lm(y~x,data=D)
reg1_2 <- lm(x~y,data=D)
reg2_1 <- lm(y1~x1,data=D_2)
reg2_2 <- lm(x1~y1,data=D_2)
c(coefficients(reg1_1)[2],coefficients(reg1_2)[2],coefficients(reg2_1)[2],coefficients(reg2_2)[2])</pre>
```

Output:

```
x y x1 y1
-1.0 -1.0 0.5 2.0
```

3.13

a)

```
set.seed(1)
x = rnorm(100)
```

b)

```
eps = rnorm(100,0,sqrt(0.25))
```

c)

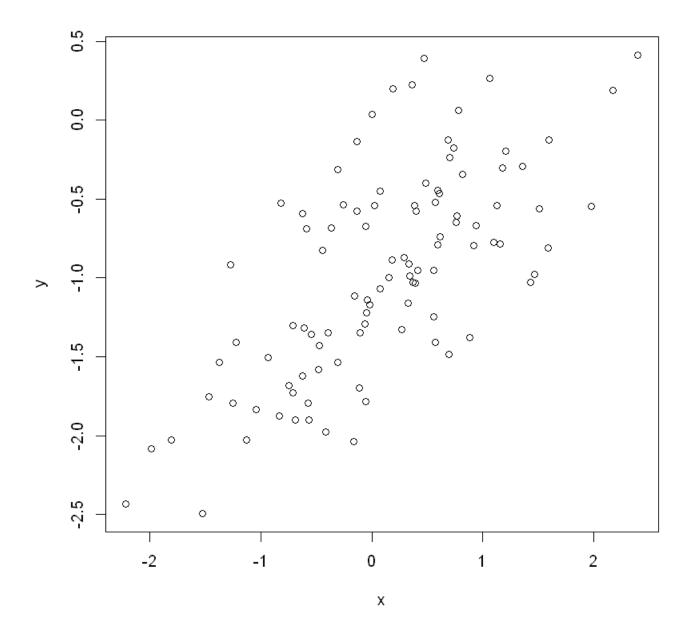
```
y = -1 + 0.5*x + eps
length(y)
```

100

y tiene longitud de 100, $\boldsymbol{\beta}_0 = -1$ y $\boldsymbol{\beta}_1 = 0.5$

d)

```
plot(x, y)
```



Se observa una realción lineal con pendiente positiva.

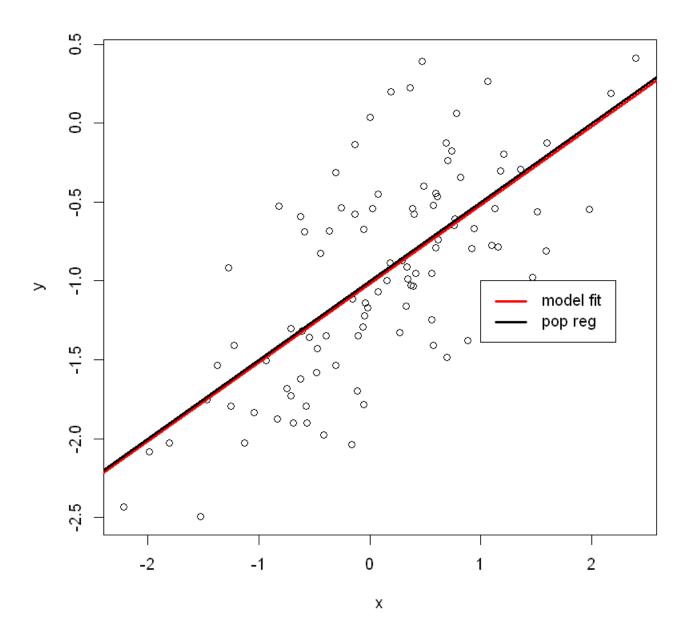
e)

```
lm.fit = lm(y~x)
summary(lm.fit)
```

Se tiene un modelo con un p-valor pequeño y una estadostica F lejana de 1. Se puede rechazar la hipótesis nula.

f)

```
plot(x, y)
abline(lm.fit, lwd=3, col=2)
abline(-1, 0.5, lwd=3, col=1)
legend(-1, legend = c("model fit", "pop reg"), col=2:1, lwd=3)
```

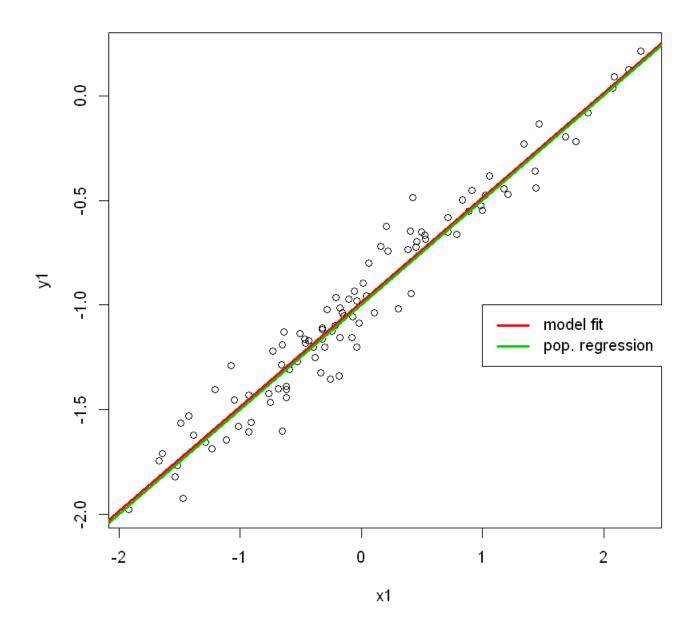


```
lm.fit_sq = lm(y~x+I(x^2))
summary(lm.fit_sq)
```

El valor de $R_{\scriptscriptstyle 2}$ aumento ligeramente, sin embargo se tiene un p-valor muy grande.

h)

```
set.seed(1)
eps1 = rnorm(100, 0, 0.125) #se disminuye var de 0.25 a 0.125
x1 = rnorm(100)
y1 = -1 + 0.5*x1 + eps1
plot(x1, y1)
lm.fit1 = lm(y1~x1)
summary(lm.fit1)
abline(lm.fit1, lwd=3, col=2)
abline(-1, 0.5, lwd=3, col=3)
legend(-1, legend = c("model fit", "pop. regression"), col=2:3, lwd=3)
```

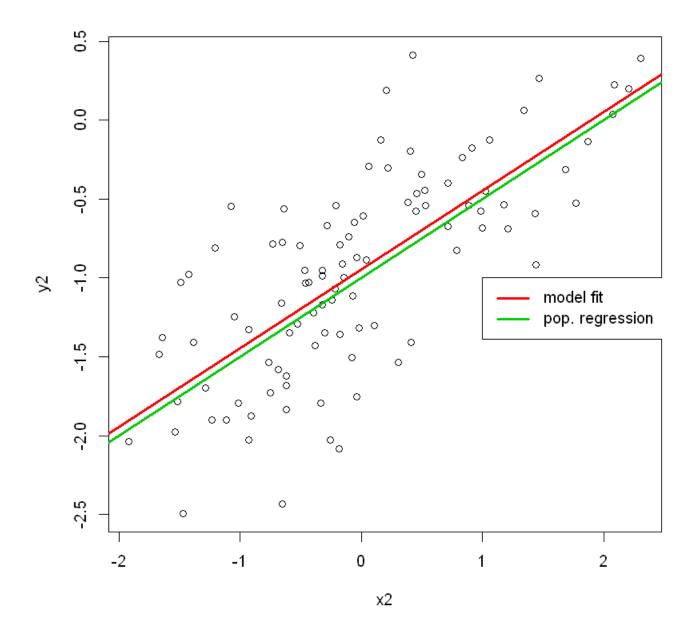


Se observo un aumento significativo en $R_{\rm 2}$ de 0.467 a 0.9479, y RSE disminuyó de 0.481 a 0.1128

i)

```
set.seed(1)
eps2 = rnorm(100, 0, 0.5) #se disminuye var de 0.25 a 0.5
x2 = rnorm(100)
y2 = -1 + 0.5*x2 + eps2
plot(x2, y2)
lm.fit2 = lm(y2~x2)
summary(lm.fit2)
abline(lm.fit2, lwd=3, col=2)
abline(-1, 0.5, lwd=3, col=3)
legend(-1, legend = c("model fit", "pop. regression"), col=2:3, lwd=3)
```

```
Call:
lm(formula = y2 \sim x2)
Residuals:
   Min
          1Q Median 3Q
                               Max
-1.16208 -0.30181 0.00268 0.29152 1.14658
Coefficients:
         Estimate Std. Error t value Pr(>|t|)
x2
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.4514 on 98 degrees of freedom
Multiple R-squared: 0.5317, Adjusted R-squared: 0.5269
F-statistic: 111.2 on 1 and 98 DF, p-value: < 2.2e-16
```



 \boldsymbol{R}_2 aumentó de 0.467 a 0.5317 y RSE disminuyó de 0.481 a 0.4514

j)

```
confint(lm.fit)
```

A matrix: 2 × 2 of type dbl

	2.5 %	97.5 %
(Intercept)	-1.1150804	-0.9226122
x	0.3925794	0.6063602

confint(lm.fit1)

A matrix: 2 × 2 of type dbl

	2.5 %	97.5 %
(Intercept)	-1.008805	-0.9639819
x 1	0.476387	0.5233799

confint(lm.fit2)

A matrix: 2 × 2 of type dbl

	2.5 %	97.5 %
(Intercept)	-1.0352203	-0.8559276
x2	0.4055479	0.5935197

3.14

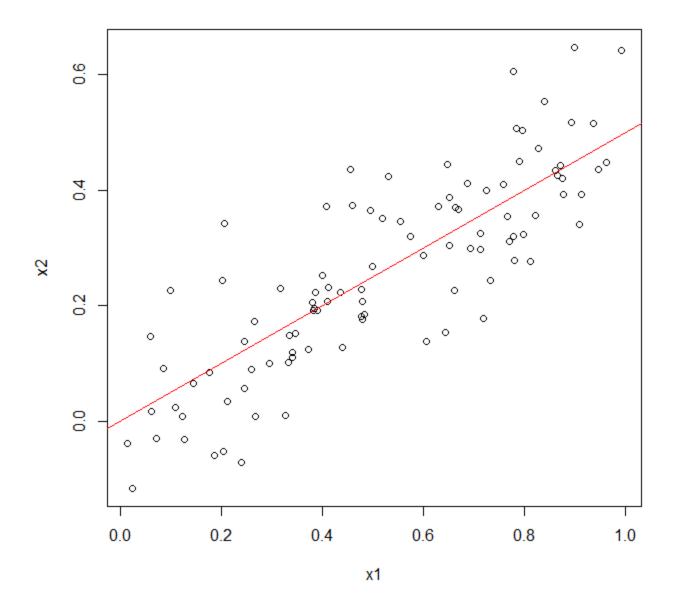
a)

$$y = 2 + 2x_1^{} + 0.3x_2^{}$$

Los coeficientes son .3 y 2.

b)

Al correr el comando cor se observa una correlación de 0.83.



Es visible existe una correlación.

c) , d) y e)

Input:

```
set.seed(1)
x1 <- runif(100)
x2 <- 0.5*x1+rnorm(100)/10
y <- 2+2*x1+.3*x2+rnorm(100)
reg1 <- lm(y ~ x1+x2)
reg2 <- lm(y ~ x1)
reg3 <- lm(y ~ x2)
summary(reg1)
summary(reg2)
summary(reg3)</pre>
```

Output:

```
Call:
lm(formula = y \sim x1 + x2)
Residuals:
   Min
          1Q Median
                         3Q
                                 Max
-2.8311 -0.7273 -0.0537 0.6338 2.3359
Coefficients:
           Estimate Std. Error t value Pr(>|t|)
(Intercept) 2.1305 0.2319 9.188 7.61e-15 ***
            1.4396
x1
                     0.7212 1.996 0.0487 *
x2
            1.0097 1.1337 0.891 0.3754
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 1.056 on 97 degrees of freedom
Multiple R-squared: 0.2088, Adjusted R-squared: 0.1925
F-statistic: 12.8 on 2 and 97 DF, p-value: 1.164e-05
Call:
lm(formula = y \sim x1)
Residuals:
    Min
            1Q Median
                              3Q
                                      Max
-2.89495 -0.66874 -0.07785 0.59221 2.45560
Coefficients:
           Estimate Std. Error t value Pr(>|t|)
(Intercept) 2.1124 0.2307 9.155 8.27e-15 ***
            1.9759
                       0.3963 4.986 2.66e-06 ***
x1
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 1.055 on 98 degrees of freedom
Multiple R-squared: 0.2024, Adjusted R-squared: 0.1942
F-statistic: 24.86 on 1 and 98 DF, p-value: 2.661e-06
Call:
lm(formula = y \sim x2)
Residuals:
    Min
            1Q Median
                               3Q
                                      Max
-2.62687 -0.75156 -0.03598 0.72383 2.44890
```

```
Coefficients:

Estimate Std. Error t value Pr(>|t|)

(Intercept) 2.3899 0.1949 12.26 < 2e-16 ***

x2 2.8996 0.6330 4.58 1.37e-05 ***

---

Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.072 on 98 degrees of freedom

Multiple R-squared: 0.1763, Adjusted R-squared: 0.1679

F-statistic: 20.98 on 1 and 98 DF, p-value: 1.366e-05
```

Se observa que en el primer modelo x1 tiene más relevancia que x2, después en los modelos subsecuentes se muestra que tienen relevancia x1 y x2 en su caso correspondiente, por lo que no es suficiente el primer modelo para descartar las hipótesis nula de ningún predictor en particular, y en cada modelo subsecuente es suficiente para afirmar la hipótesis nula del predictor contrario al usado en cada modelo.

f)

Los modelos no se contradicen, pues en el primero se muestra que en presencia de esos dos predictores uno no es relevante, eso no quiere decir que solo no sean relevantes.

g)

Input:

```
x1=c(x1,.1)
x2=c(x2,.8)
y=c(y,6)
reg1_2 <- lm(y ~ x1+x2)
reg2_2 <- lm(y ~ x1)
reg3_2 <- lm(y ~ x2)
summary(reg1_2)
summary(reg2_2)
summary(reg3_2)
par(mfrow = c(3,4))
plot(reg1_2)
plot(reg2_2)
plot(reg3_2)</pre>
```

Output:

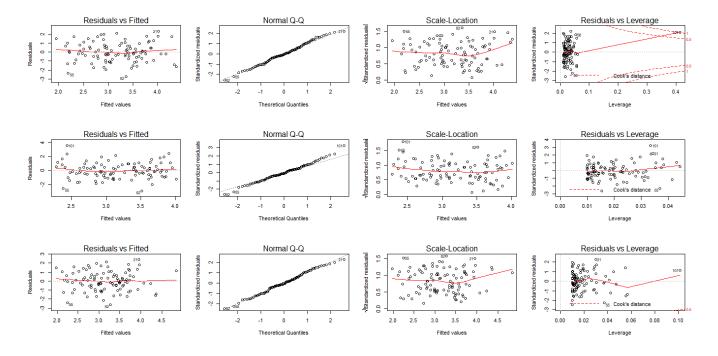
```
Call:
lm(formula = y \sim x1 + x2)
Residuals:
    Min
              1Q Median
                               3Q
                                       Max
-2.73348 -0.69318 -0.05263 0.66385 2.30619
Coefficients:
           Estimate Std. Error t value Pr(>|t|)
(Intercept) 2.2267 0.2314 9.624 7.91e-16 ***
            0.5394 0.5922 0.911 0.36458
x1
x2
            2.5146 0.8977 2.801 0.00614 **
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 1.075 on 98 degrees of freedom
Multiple R-squared: 0.2188, Adjusted R-squared: 0.2029
F-statistic: 13.72 on 2 and 98 DF, p-value: 5.564e-06
Call:
lm(formula = y \sim x1)
Residuals:
         10 Median 30
                                  Max
-2.8897 -0.6556 -0.0909 0.5682 3.5665
Coefficients:
           Estimate Std. Error t value Pr(>|t|)
(Intercept) 2.2569 0.2390 9.445 1.78e-15 ***
                    0.4124 4.282 4.29e-05 ***
x1
             1.7657
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 1.111 on 99 degrees of freedom
Multiple R-squared: 0.1562, Adjusted R-squared: 0.1477
F-statistic: 18.33 on 1 and 99 DF, p-value: 4.295e-05
Call:
lm(formula = y \sim x2)
Residuals:
    Min
              1Q Median
                               3Q
                                       Max
```

En el primer modelo se observa que el predictor menos relevante cambió, ahora x2 es más relevate.

En los dos modelos subsecuentes no hay cambio importante aparte de un ligero aumento en el error.

Observando las graficas de los modelos en todas se nota una desviación en la gráfica de Residuals vs Leverage debido al punto recién introducido, siendo ligeramente menor el efecto en el segundo modelo.

Cabe resaltar que es en este segundo modelo que se usa x2 por lo que implica que existe una relación entre un Leverage menor y la relevancia en el modelo general del predictor en cuestión.

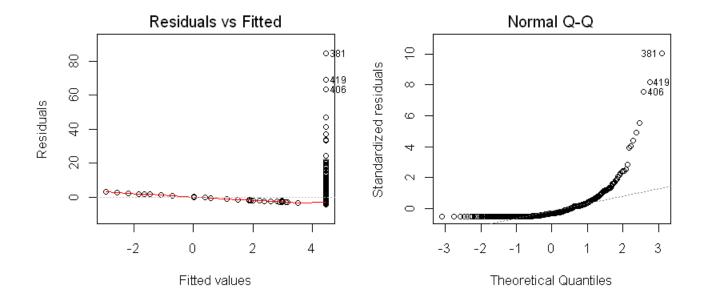


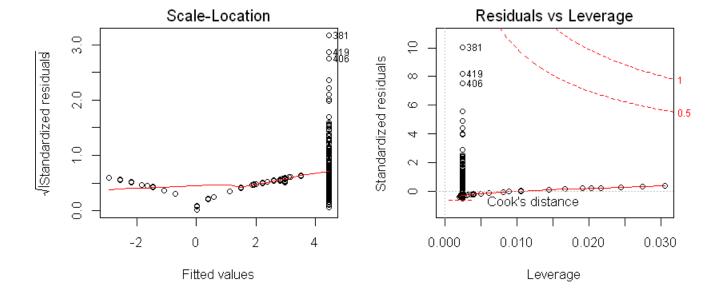
3.15

a)

```
library(MASS)
attach(Boston)
lm.zn = lm(crim~zn) #crimen y zonas residenciales 25,000 sq ft
summary(lm.zn)
par(mfrow=c(2,2))
plot(lm.zn)
```

```
The following objects are masked from Boston (pos = 3):
   age, black, chas, crim, dis, indus, lstat, medv, nox, ptratio, rad,
   rm, tax, zn
Call:
lm(formula = crim ~ zn)
Residuals:
  Min 1Q Median 3Q
                           Max
-4.429 -4.222 -2.620 1.250 84.523
Coefficients:
          Estimate Std. Error t value Pr(>|t|)
(Intercept) 4.45369 0.41722 10.675 < 2e-16 ***
         zn
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 8.435 on 504 degrees of freedom
Multiple R-squared: 0.04019, Adjusted R-squared: 0.03828
F-statistic: 21.1 on 1 and 504 DF, p-value: 5.506e-06
```





```
lm.indus = lm(crim~indus) #crimen y non retail business acres
summary(lm.indus)
par(mfrow=c(2,2))
#plot(lm.indus)
```

```
Call:
   lm(formula = crim ~ indus)
   Residuals:
      Min 1Q Median 3Q
                                  Max
   -11.972 -2.698 -0.736 0.712 81.813
   Coefficients:
             Estimate Std. Error t value Pr(>|t|)
   indus 0.50978 0.05102 9.991 < 2e-16 ***
   Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
   Residual standard error: 7.866 on 504 degrees of freedom
   Multiple R-squared: 0.1653, Adjusted R-squared: 0.1637
   F-statistic: 99.82 on 1 and 504 DF, p-value: < 2.2e-16
lm.chas = lm(crim~chas) #crimen y cercania al rio charles
summary(lm.chas)
par(mfrow=c(2,2))
plot(lm.chas)
   Call:
   lm(formula = crim ~ chas)
   Residuals:
     Min
          1Q Median 3Q
                              Max
   -3.738 -3.661 -3.435 0.018 85.232
   Coefficients:
             Estimate Std. Error t value Pr(> t | )
   (Intercept) 3.7444 0.3961 9.453 <2e-16 ***
   chas
             -1.8928
                       1.5061 -1.257 0.209
```

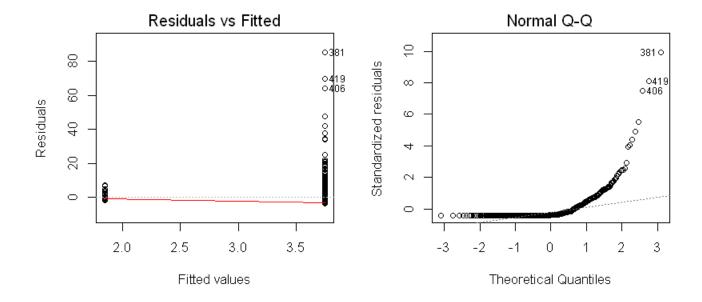
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

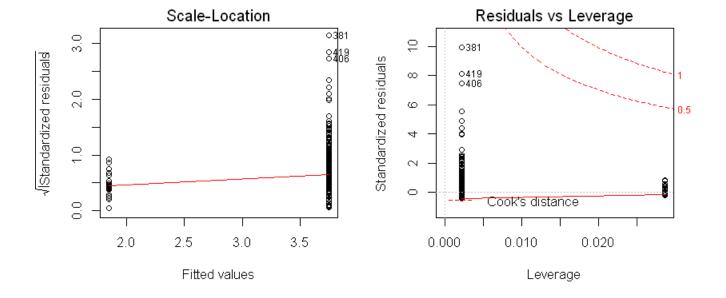
Multiple R-squared: 0.003124, Adjusted R-squared: 0.001146

Residual standard error: 8.597 on 504 degrees of freedom

F-statistic: 1.579 on 1 and 504 DF, p-value: 0.2094

_ _ _





```
lm.nox = lm(crim~nox) #crimen y concentraciones de oxidos de nitrogeno
summary(lm.nox)
par(mfrow=c(2,2))
#plot(lm.nox)
```

```
Call:
   lm(formula = crim ~ nox)
   Residuals:
       Min 1Q Median 3Q
                                     Max
   -12.371 -2.738 -0.974 0.559 81.728
   Coefficients:
             Estimate Std. Error t value Pr(>|t|)
   (Intercept) -13.720 1.699 -8.073 5.08e-15 ***
               31.249 2.999 10.419 < 2e-16 ***
   nox
   Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
   Residual standard error: 7.81 on 504 degrees of freedom
   Multiple R-squared: 0.1772, Adjusted R-squared: 0.1756
   F-statistic: 108.6 on 1 and 504 DF, p-value: < 2.2e-16
lm.rm = lm(crim~rm) #crimen y numero promedio de habitaciones por vivienda
summary(lm.rm)
par(mfrow=c(2,2))
#plot(lm.rm)
   Call:
   lm(formula = crim ~ rm)
   Residuals:
      Min 1Q Median 3Q Max
   -6.604 -3.952 -2.654 0.989 87.197
   Coefficients:
              Estimate Std. Error t value Pr(> t | )
   (Intercept) 20.482 3.365 6.088 2.27e-09 ***
               -2.684 0.532 -5.045 6.35e-07 ***
   rm
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Multiple R-squared: 0.04807, Adjusted R-squared: 0.04618

Residual standard error: 8.401 on 504 degrees of freedom

F-statistic: 25.45 on 1 and 504 DF, p-value: 6.347e-07

```
lm.age = lm(crim~age) #crimen y edad del edificio
summary(lm.age)
par(mfrow=c(2,2))
#plot(lm.age)
```

```
Call:
lm(formula = crim ~ age)
Residuals:
  Min
      1Q Median 3Q Max
-6.789 -4.257 -1.230 1.527 82.849
Coefficients:
         Estimate Std. Error t value Pr(>|t|)
0.10779 0.01274 8.463 2.85e-16 ***
age
___
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 8.057 on 504 degrees of freedom
Multiple R-squared: 0.1244, Adjusted R-squared: 0.1227
F-statistic: 71.62 on 1 and 504 DF, p-value: 2.855e-16
```

```
lm.dis = lm(crim~dis) #crimen y distancia a entros de empleo
summary(lm.dis)
par(mfrow=c(2,2))
#plot(lm.dis)
```

```
Call:
   lm(formula = crim ~ dis)
   Residuals:
     Min 1Q Median 3Q Max
   -6.708 -4.134 -1.527 1.516 81.674
   Coefficients:
            Estimate Std. Error t value Pr(>|t|)
   (Intercept) 9.4993 0.7304 13.006 <2e-16 ***
                       0.1683 -9.213 <2e-16 ***
   dis
          -1.5509
   Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
   Residual standard error: 7.965 on 504 degrees of freedom
   Multiple R-squared: 0.1441, Adjusted R-squared: 0.1425
   F-statistic: 84.89 on 1 and 504 DF, p-value: < 2.2e-16
lm.rad = lm(crim~rad) #crimen y cercania a carreteras
summary(lm.rad)
par(mfrow=c(2,2))
#plot(lm.rad)
   Call:
   lm(formula = crim ~ rad)
   Residuals:
      Min 1Q Median 3Q Max
   -10.164 -1.381 -0.141 0.660 76.433
   Coefficients:
             Estimate Std. Error t value Pr(>|t|)
   rad
             0.61791 0.03433 17.998 < 2e-16 ***
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Multiple R-squared: 0.3913, Adjusted R-squared: 0.39

Residual standard error: 6.718 on 504 degrees of freedom

F-statistic: 323.9 on 1 and 504 DF, p-value: < 2.2e-16

```
lm.tax = lm(crim~tax) #crimen e impuestos
summary(lm.tax)
par(mfrow=c(2,2))
#plot(lm.tax)
```

```
lm.ptratio = lm(crim~ptratio) #crimen y taza de maestros promedio
summary(lm.ptratio)
par(mfrow=c(2,2))
#plot(lm.ptratio)
```

```
Call:
   lm(formula = crim ~ ptratio)
   Residuals:
     Min 1Q Median 3Q Max
   -7.654 -3.985 -1.912 1.825 83.353
   Coefficients:
              Estimate Std. Error t value Pr(>|t|)
   (Intercept) -17.6469 3.1473 -5.607 3.40e-08 ***
                         0.1694 6.801 2.94e-11 ***
   ptratio 1.1520
   Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
   Residual standard error: 8.24 on 504 degrees of freedom
   Multiple R-squared: 0.08407, Adjusted R-squared: 0.08225
   F-statistic: 46.26 on 1 and 504 DF, p-value: 2.943e-11
lm.black = lm(crim~black) #crimen y poblacion de afro americanos
summary(lm.black)
par(mfrow=c(2,2))
#plot(lm.black)
   Call:
   lm(formula = crim ~ black)
   Residuals:
       Min 1Q Median 3Q
   -13.756 -2.299 -2.095 -1.296 86.822
   Coefficients:
               Estimate Std. Error t value Pr(>|t|)
   (Intercept) 16.553529    1.425903    11.609    <2e-16 ***
   black -0.036280 0.003873 -9.367 <2e-16 ***
   Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
   Residual standard error: 7.946 on 504 degrees of freedom
   Multiple R-squared: 0.1483, Adjusted R-squared: 0.1466
   F-statistic: 87.74 on 1 and 504 DF, p-value: < 2.2e-16
```

```
lm.lstat = lm(crim~lstat) #crimen y porcentaje de poblacion de status bajo
summary(lm.lstat)
par(mfrow=c(2,2))
#plot(lm.lstat)
```

```
lm.medv = lm(crim~medv) #crimen y valo medio de casas ocupadas en $1000s
summary(lm.medv)
par(mfrow=c(2,2))
#plot(lm.medv)
```

No se pudo hacer regresion con el parametro chas ya que este es cualitativo.

Basado en los valores de la estadistica - F algunso de los predicotres más significativos son nox, rad y tax.

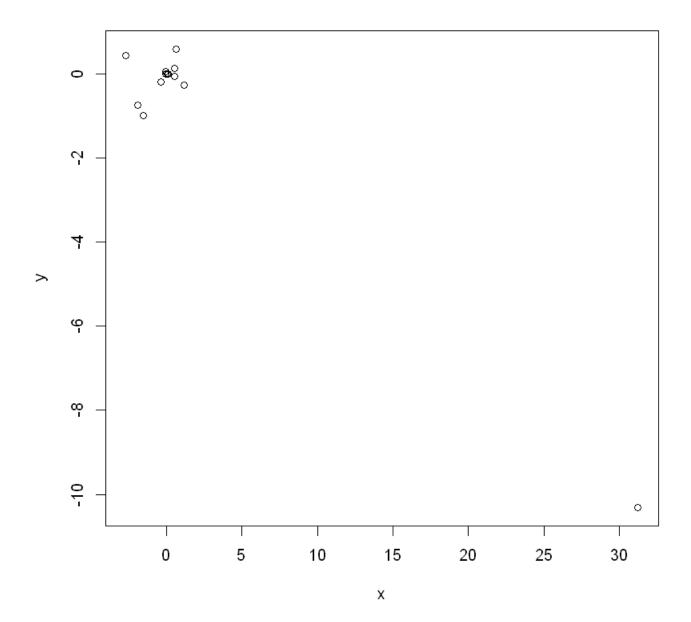
b)

```
lm.all = lm(crim~., data=Boston) #crimen y todos los predictores
summary(lm.all)
```

```
Call:
lm(formula = crim ~ ., data = Boston)
Residuals:
  Min
        1Q Median
                  3Q
                       Max
-9.924 -2.120 -0.353 1.019 75.051
Coefficients:
          Estimate Std. Error t value Pr(>|t|)
(Intercept) 17.033228 7.234903 2.354 0.018949 *
         0.044855 0.018734 2.394 0.017025 *
indus
        -0.749134 1.180147 -0.635 0.525867
chas
        -10.313535 5.275536 -1.955 0.051152 .
nox
         0.430131 0.612830 0.702 0.483089
rm
         0.001452 0.017925 0.081 0.935488
age
         dis
         rad
tax
         -0.003780 0.005156 -0.733 0.463793
ptratio
        -0.271081 0.186450 -1.454 0.146611
         black
         0.126211 0.075725 1.667 0.096208 .
lstat
         medv
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 6.439 on 492 degrees of freedom
Multiple R-squared: 0.454, Adjusted R-squared: 0.4396
F-statistic: 31.47 on 13 and 492 DF, p-value: < 2.2e-16
```

Los predictores dis,rad y medv tiene p-valores más pequeños comparados con los demás, por tanto se puede descartar la hipotesus núla en estos.

c)



El coeficiente para nox es diferente en regresion simple (-10)y regresion multiple (30).

d)

```
lm.zn = lm(crim~poly(zn,3))
summary(lm.zn)
```

```
lm.indus = lm(crim~poly(indus,3))
summary(lm.indus)
```

```
Call:
    lm(formula = crim ~ poly(indus, 3))
    Residuals:
       Min 1Q Median 3Q
                                       Max
    -8.278 -2.514 0.054 0.764 79.713
    Coefficients:
                    Estimate Std. Error t value Pr(>|t|)
    (Intercept) 3.614 0.330 10.950 < 2e-16 ***
    poly(indus, 3)1 78.591 7.423 10.587 < 2e-16 ***
poly(indus, 3)2 -24.395 7.423 -3.286 0.00109 **
poly(indus, 3)3 -54.130 7.423 -7.292 1.2e-12 ***
    Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
    Residual standard error: 7.423 on 502 degrees of freedom
    Multiple R-squared: 0.2597, Adjusted R-squared: 0.2552
    F-statistic: 58.69 on 3 and 502 DF, p-value: < 2.2e-16
lm.nox = lm(crim~poly(nox,3))
summary(lm.nox)
    Call:
    lm(formula = crim ~ poly(nox, 3))
    Residuals:
       Min
             1Q Median 3Q
                                       Max
    -9.110 -2.068 -0.255 0.739 78.302
    Coefficients:
                    Estimate Std. Error t value Pr(>|t|)
    (Intercept) 3.6135 0.3216 11.237 < 2e-16 ***
    poly(nox, 3)1 81.3720 7.2336 11.249 < 2e-16 ***
poly(nox, 3)2 -28.8286 7.2336 -3.985 7.74e-05 ***
poly(nox, 3)3 -60.3619 7.2336 -8.345 6.96e-16 ***
    Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 7.234 on 502 degrees of freedom

F-statistic: 70.69 on 3 and 502 DF, p-value: < 2.2e-16

Multiple R-squared: 0.297, Adjusted R-squared: 0.2928

```
lm.rm = lm(crim~poly(rm,3))
summary(lm.rm)
```

```
lm.age = lm(crim~poly(age,3))
summary(lm.age)
```

```
Call:
   lm(formula = crim ~ poly(age, 3))
   Residuals:
      Min 1Q Median 3Q
                                 Max
   -9.762 -2.673 -0.516 0.019 82.842
   Coefficients:
                Estimate Std. Error t value Pr(>|t|)
   (Intercept) 3.6135 0.3485 10.368 < 2e-16 ***
   poly(age, 3)1 68.1820 7.8397 8.697 < 2e-16 ***
poly(age, 3)2 37.4845 7.8397 4.781 2.29e-06 ***
poly(age, 3)3 21.3532 7.8397 2.724 0.00668 **
   Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
   Residual standard error: 7.84 on 502 degrees of freedom
   Multiple R-squared: 0.1742, Adjusted R-squared: 0.1693
   F-statistic: 35.31 on 3 and 502 DF, p-value: < 2.2e-16
lm.dis = lm(crim~poly(dis,3))
summary(lm.dis)
   Call:
   lm(formula = crim ~ poly(dis, 3))
   Residuals:
       Min 1Q Median 3Q Max
   -10.757 -2.588 0.031 1.267 76.378
   Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
   (Intercept) 3.6135 0.3259 11.087 < 2e-16 ***
   Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
   Residual standard error: 7.331 on 502 degrees of freedom
   Multiple R-squared: 0.2778, Adjusted R-squared: 0.2735
   F-statistic: 64.37 on 3 and 502 DF, p-value: < 2.2e-16
```

```
lm.rad = lm(crim~poly(rad,3))
summary(lm.rad)
```

```
lm.tax = lm(crim~poly(tax,3))
summary(lm.tax)
```

```
Call:
   lm(formula = crim ~ poly(tax, 3))
   Residuals:
       Min 1Q Median
                             3Q
                                     Max
   -13.273 -1.389 0.046 0.536 76.950
   Coefficients:
                Estimate Std. Error t value Pr(>|t|)
   (Intercept) 3.6135 0.3047 11.860 < 2e-16 ***
   poly(tax, 3)1 112.6458
                           6.8537 16.436 < 2e-16 ***
   poly(tax, 3)2 32.0873 6.8537 4.682 3.67e-06 ***
poly(tax, 3)3 -7.9968 6.8537 -1.167 0.244
   Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
   Residual standard error: 6.854 on 502 degrees of freedom
   Multiple R-squared: 0.3689, Adjusted R-squared: 0.3651
   F-statistic: 97.8 on 3 and 502 DF, p-value: < 2.2e-16
lm.ptratio = lm(crim~poly(ptratio,3))
summary(lm.ptratio)
   Call:
   lm(formula = crim ~ poly(ptratio, 3))
   Residuals:
            1Q Median 3Q
      Min
                                 Max
   -6.833 -4.146 -1.655 1.408 82.697
   Coefficients:
                    Estimate Std. Error t value Pr(>|t|)
                  3.614 0.361 10.008 < 2e-16 ***
   (Intercept)
   poly(ptratio, 3)1 56.045
                                8.122 6.901 1.57e-11 ***
   poly(ptratio, 3)2 24.775 8.122 3.050 0.00241 **
   poly(ptratio, 3)3 -22.280
                                8.122 -2.743 0.00630 **
   Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
   Residual standard error: 8.122 on 502 degrees of freedom
   Multiple R-squared: 0.1138, Adjusted R-squared: 0.1085
   F-statistic: 21.48 on 3 and 502 DF, p-value: 4.171e-13
```

```
lm.black = lm(crim~poly(black,3))
summary(lm.black)
```

```
lm.lstat = lm(crim~poly(lstat,3))
summary(lm.lstat)
```

```
Call:
   lm(formula = crim ~ poly(lstat, 3))
   Residuals:
       Min 1Q Median 3Q
                                       Max
   -15.234 -2.151 -0.486 0.066 83.353
   Coefficients:
                  Estimate Std. Error t value Pr(>|t|)
   (Intercept) 3.6135 0.3392 10.654 <2e-16 ***
   poly(lstat, 3)1 88.0697 7.6294 11.543 <2e-16 **
poly(lstat, 3)2 15.8882 7.6294 2.082 0.0378 *
poly(lstat, 3)3 -11.5740 7.6294 -1.517 0.1299
                              7.6294 11.543 <2e-16 ***
   Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
   Residual standard error: 7.629 on 502 degrees of freedom
   Multiple R-squared: 0.2179, Adjusted R-squared: 0.2133
   F-statistic: 46.63 on 3 and 502 DF, p-value: < 2.2e-16
lm.medv = lm(crim~poly(medv,3))
summary(lm.medv)
   Call:
   lm(formula = crim ~ poly(medv, 3))
   Residuals:
       Min 1Q Median 3Q
                                       Max
   -24.427 -1.976 -0.437 0.439 73.655
   Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
   (Intercept) 3.614 0.292 12.374 < 2e-16 ***
   poly(medv, 3)1 -75.058
                              6.569 -11.426 < 2e-16 ***
   poly(medv, 3)2 88.086
                              6.569 13.409 < 2e-16 ***
   poly(medv, 3)3 -48.033 6.569 -7.312 1.05e-12 ***
   Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
   Residual standard error: 6.569 on 502 degrees of freedom
   Multiple R-squared: 0.4202, Adjusted R-squared: 0.4167
   F-statistic: 121.3 on 3 and 502 DF, p-value: < 2.2e-16
```

Si hay evidencia de no linealidad para todos los predictores a excepcion de black y chas.